



UNCOVER

Case Técnico Data Science

Aplicação de Marketing Mix Modeling

Sobre este case

Este é o case técnico para a vaga de **Data Scientist Júnior** na Uncover. Você tem **7 dias corridos** a partir do recebimento para enviar sua solução. A base de dados (varejo360_weekly.csv) está anexada junto a este documento.

Na próxima etapa do processo, você apresentará o case em uma entrevista técnica. **Não é obrigatório preparar uma apresentação formal (slides)**, o que importa é você conseguir discutir, defender suas decisões e responder perguntas sobre o que construiu. O próprio notebook ou script pode servir de apoio durante a conversa. De qualquer forma, os arquivos da sua solução devem ser enviados dentro do prazo de 7 dias corridos.

O objetivo deste desafio **não** é um modelo perfeito, é entender **como você pensa**. Priorizamos a qualidade do raciocínio, a clareza das decisões metodológicas e a honestidade sobre limitações acima da sofisticação técnica. Se algum ponto do case parecer fora do seu escopo atual, documente a limitação e siga em frente, um modelo simples bem justificado vale mais do que um modelo complexo mal fundamentado.

Introdução ao Marketing Mix Modeling

Esta seção apresenta os conceitos fundamentais de MMM. Leia com atenção antes de responder às perguntas do case.

O que é MMM?

Definição

MMM é um conjunto de técnicas estatísticas que estima a contribuição de cada fator de marketing e negócio sobre uma variável de resultado — tipicamente vendas ou receita. O objetivo central é responder:

"Quanto das nossas vendas foram causadas pela TV, pelo digital, pela promoção de preço, ou pelo contexto externo (calor, Copa do Mundo)?"

O MMM trabalha com dados agregados de série temporal — tipicamente semanas ou meses — e captura o efeito de todas as mídias, incluindo canais offline como TV e rádio, que são invisíveis para sistemas de atribuição digital.

A Equação Base

A formulação mais simples é uma regressão múltipla:

$$\text{Vendas}(t) = \alpha + \beta_1 \cdot \text{Mídia}_1(t) + \beta_2 \cdot \text{Mídia}_2(t) + \dots + \beta_n \cdot \text{Controles}(t) + \varepsilon(t)$$

Termo	Significado
α (intercepto)	Vendas de base: o que se venderia sem nenhum esforço de mídia
β (coeficientes)	Efeito marginal de cada variável sobre as vendas
Controles	Variáveis não-mídia: preço, temperatura, sazonalidade, distribuição
ε (erro)	O que o modelo não consegue explicar

Transformações Essenciais de Mídia

Mídia não age de forma linear nem instantânea. Duas transformações são fundamentais:

1. Adstock com Geometric Decay

O impacto de uma campanha de TV persiste por semanas após o último GRP veiculado. O geometric decay modela isso como uma soma ponderada de todos os investimentos passados, onde o peso de cada período cai geometricamente com o tempo:

$$\text{Adstock}(t) = \sum \lambda^k \cdot \text{Investimento}(t - k), \quad k = 0, 1, 2, \dots$$

O peso do período $t-k$ é λ^k : no período corrente ($k=0$) o peso é 1; na semana anterior ($k=1$) é λ ; duas semanas atrás ($k=2$) é λ^2 , e assim por diante. Isso equivale à recursão:

$$\text{Adstock}(t) = \text{Investimento}(t) + \lambda \times \text{Adstock}(t-1)$$

onde $\lambda \in [0, 1)$ é a taxa de retenção. $\lambda = 0$ significa sem memória (só o período corrente conta); λ próximo de 1 significa memória longa. TV tipicamente tem λ alto (0.5–0.8); Search tem λ próximo de zero.

2. Saturação (Rendimentos Decrescentes)

Os primeiros R\$100k em TV têm mais impacto que os R\$100k seguintes. A curva Hill captura isso:

$$\text{Saturação}(x) = x^n / (K^n + x^n)$$

onde K é o ponto de meia-saturação e n controla a curvatura. O resultado fica entre 0 e 1.

Glossário Mínimo

Termo	Definição
KPI / Target variable	A variável a prever (ex: volume de vendas, receita bruta)
Incrementalidade	Vendas adicionais causadas pela mídia acima do que teria ocorrido sem ela
Baseline	Nível de vendas esperado sem nenhuma ação de mídia
ROI de mídia	Receita incremental gerada por R\$1 investido em determinado canal
Multicolinearidade	Quando duas variáveis explicativas são muito correlacionadas, dificultando estimar efeitos individuais
Distribuição Numérica	% de pontos de venda onde o produto está disponível
Adstock	Transformação que captura o efeito de memória/decaimento da mídia no tempo

Na prática: Case de MMM

1. Escopo do Modelo: Varejo

Contexto

A **Varejo360** é um dos maiores e-commerces de moda e acessórios do Brasil, com atuação nacional, portfólio de marcas próprias e multimarcas, e base de clientes ativa de mais de 2 milhões de compradores. A empresa investe de forma consistente em múltiplos canais de mídia — desde TV e OOH até campanhas de performance digital e CRM — e possui um programa consolidado de afiliados e influenciadores.

O time de planejamento de mídia precisa tomar uma decisão crítica: **como realocar o orçamento de marketing para o próximo ano fiscal?** Para isso, a liderança contratou uma análise de **Marketing Mix Modeling (MMM)** com o objetivo de responder:

"Qual é a contribuição causal de cada canal de mídia nas vendas da Varejo360, e qual o retorno sobre investimento (ROI) de cada um?"

Os resultados serão apresentados diretamente ao CMO e utilizados para definir a estratégia de mídia do próximo ciclo.

2.1 Dataset: Descrição das Variáveis

O arquivo `varejo360_weekly.csv` contém **157 semanas de dados** (janeiro de 2022 a dezembro de 2024). A granularidade é semanal, com semanas iniciando sempre na segunda-feira.

Dicionário de Dados

Coluna	Tipo	Descrição
<code>date</code>	string	Data de início da semana (YYYY-MM-DD)
<code>units_sold</code>	int	Unidades vendidas na semana
<code>revenue_br1</code>	float	Receita bruta em R\$
<code>avg_price_br1</code>	float	Preço médio ponderado por unidade vendida (R\$)
<code>tv_spend_br1</code>	float	Investimento em TV aberta e streaming (R\$)
<code>google_search_spend_br1</code>	float	Investimento em Google Search Ads (R\$)
<code>google_display_spend_br1</code>	float	Investimento em Google Display Network (R\$)

meta_spend_br1	float	Investimento em Meta Ads - Facebook + Instagram (R\$)
ooh_spend_br1	float	Investimento em Out-of-Home - painéis, busdoor, mídia exterior (R\$)
email_crm_sends	int	Volume de e-mails enviados via CRM na semana
influencer_spend_br1	float	Investimento em campanhas com influenciadores (R\$)
leads_generated	int	Leads capturados via formulários e landing pages
website_sessions	int	Total de sessões no site na semana
coupons_redeemed	int	Cupons de desconto resgatados na semana
affiliate_commission_br1	float	Comissão total paga ao programa de afiliados (R\$)
competitor_promo_index	float	Índice de intensidade promocional dos concorrentes (0 a 1)
economic_confidence_index	float	Índice de confiança do consumidor (normalizado)
is_black_friday	int	Semana de Black Friday - 1 ou 0
holiday_week	int	Semana com feriado nacional de alto impacto no varejo - 1 ou 0

⚠ Atenção

Nem todas as variáveis disponíveis são inputs válidos para um modelo de MMM. Identificar quais variáveis devem ou não entrar no modelo e justificar essa decisão com rigor é parte central do desafio.

2.2 Variável Target

Você deve escolher **uma** das duas opções abaixo e construir o modelo para ela. Justifique sua escolha.

Opção	Target	Observação
A	revenue_br1 - Receita em R\$	Avalie com atenção quais variáveis, se incluídas, introduzem viés estrutural nas estimativas
B	units_sold - Unidades vendidas	Considere o papel e o tratamento adequado da variável de preço

2.3 Etapas do Desafio

Etapa 1: Mapeamento das Variáveis

Antes de modelar, você precisa decidir quais variáveis do dataset devem ou não devem entrar como input do modelo de MMM. Espera-se:

- Classificar as variáveis em pelo menos três grupos: (i) inputs de mídia válidos, (ii) variáveis de controle/contexto, e (iii) variáveis que não devem entrar no modelo
- Justificar cada exclusão com base no raciocínio sobre as relações entre as variáveis — por exemplo: quais são causas das vendas, quais são consequências, quais competem pela mesma causa (não basta apontar correlação ou intuição).
- Ser consistente com o target escolhido.

Etapa 2: Análise Exploratória (EDA)

Realize uma EDA que vá além de estatísticas descritivas básicas. Por exemplo:

- Decomposição das séries temporais dos targets: tendência, sazonalidade, resíduos
- Análise de padrões de investimento por canal (flighting, sazonalidade de mídia, correlação entre canais)
- Estudo de multicolinearidade entre as variáveis independentes
- Análise de outliers e eventos especiais
- Identificação de desafios de identificação causal presentes nos dados

A EDA deve **informar e justificar** as decisões de modelagem tomadas na Etapa 3.

Etapa 3: Modelo MMM

Construa um Marketing Mix Model:

- Aplicar transformações de **adstock** (memória publicitária) nos canais de mídia
- Aplicar transformações de **saturação** (retornos decrescentes) onde aplicável
- Estimar a **contribuição incremental de cada canal** no target escolhido
- Produzir **curvas de resposta** (*response curves*) por canal
- Estimar o **ROI** de cada canal

⚠ Atenção

Sobre a calibração das transformações: não esperamos otimização fina dos hiperparâmetros de adstock e saturação. Você pode usar valores fixos razoáveis ou um grid search simples via cross-validation. O importante é você entender o papel de cada transformação, aplicá-las corretamente e justificar suas escolhas — não é necessário usar frameworks de otimização bayesiana ou implementar tuning próprio sofisticado.

A escolha de framework é livre. Algumas opções:

- [pymc-marketing](#) - MMM bayesiano com PyMC
- [prophetverse](#) - MMM bayesiano
- [meridian](#) - MMM do Google
- [Robyn](#) - MMM do Meta (R)
- Implementação própria com [statsmodels](#), [scikit-learn](#), ou qualquer outro framework

Etapa 4: Seleção de Variáveis

- Teste adicionar cada uma das variáveis adicionais ao modelo. Para cada uma: o WAPE melhora ou piora? Os coeficientes fazem sentido?
- Com base nessas análises, defina o conjunto final de variáveis e justifique cada inclusão e exclusão.

3. Entregáveis

1. **Notebook ou script** com todo o código, reproduzível do zero
2. **Análise e resultados** — pode ser o próprio notebook — contendo:
 - Justificativa das escolhas metodológicas (especialmente exclusão de variáveis)
 - Contribuições por canal, ROIs e curvas de resposta
 - MAPE no dataset de validação, coeficientes das variáveis e seus sinais.
 - Discussão crítica sobre limitações do modelo e próximos passos

4. Dicas Técnicas

Poder Preditivo ≠ Inferência Causal

Métricas como **WAPE** (*Weighted Absolute Percentage Error*) e **R²** medem capacidade preditiva. Um modelo com WAPE baixo ou R² alto não é, necessariamente, um modelo com estimativas causais corretas.

É possível que variáveis incluídas para melhorar o ajuste introduzam viés sistemático nas estimativas dos coeficientes de mídia. Em MMM, o objetivo **não é predição**, é estimação causal. Avalie seus resultados com essa distinção em mente, e discuta explicitamente o *trade-off* entre ajuste e identificação causal.

Nota sobre os Dados

Os dados são sintéticos, gerados a partir de um modelo com parâmetros conhecidos. Isso nos permite avaliar sua solução de forma mais objetiva, mas não esperamos que seu modelo recupere os "verdadeiros" valores com precisão. O que avaliamos é a **qualidade do raciocínio**: como você identifica, justifica e trata as decisões não triviais que o case apresenta.

Boa sorte.